

Teoria dos Grafos Aplicada na Análise de Fatores de Risco para Diabetes Tipo 2

1st Eduardo da Silva Torres Grillo

CEFET-MG - Campus V

Divinópolis, Brasil

edgrillocefet@gmail.com

Resumo—O diabetes tipo 2 é um dos maiores desafios de saúde global, devido às suas associações com comorbidades metabólicas e cardiovasculares. Este estudo utiliza a teoria dos grafos para modelar as inter-relações entre fatores de risco e identificar padrões significativos que auxiliem no manejo da condição. Os resultados evidenciaram fortes associações entre diabetes, hipertensão, colesterol elevado, obesidade e doenças cardiovasculares, além de conexões significativas com saúde mental e mobilidade. Essas evidências reforçam a importância de estratégias preventivas focadas nos principais fatores de risco e na integração de abordagens multidisciplinares.

Palavras-Chave—Diabetes tipo 2, teoria dos grafos, análise de correlação, fatores de risco, hipertensão, obesidade, saúde pública.

I. INTRODUÇÃO

O diabetes mellitus tipo 2 (DM2) é uma síndrome metabólica crônica e progressiva, considerada um dos maiores desafios de saúde pública global. Representando de 90% a 95% dos casos de diabetes, o DM2 acomete milhões de pessoas e está associado a complicações graves, como doenças cardiovasculares, nefropatia e neuropatia. Além disso, impacta significativamente a qualidade de vida e a mortalidade [6], [8]. De acordo com a Organização Mundial da Saúde (OMS), projeta-se que, até 2045, aproximadamente 693 milhões de pessoas serão afetadas pelo diabetes em todo o mundo [8].

A principal característica do DM2 é a resistência à insulina, frequentemente acompanhada por secreção insuficiente desse hormônio pelas células β pancreáticas. Essa condição é agravada por fatores genéticos, envelhecimento e obesidade, sendo esta última reconhecida como o principal fator de risco passível de modificação [6], [8]. Os sintomas mais comuns incluem poliúria, polidipsia, polifagia e perda de peso involuntária. Contudo, a ausência de manifestações clínicas nos estágios iniciais dificulta o diagnóstico precoce [8].

O DM2 também está associado a outros fatores de risco, como hipertensão arterial, dislipidemia, sedentarismo e padrões alimentares inadequados, inserindo-se em um espectro mais amplo de distúrbios metabólicos. Estudos apontam que essas condições estão interligadas de maneira complexa, dificultando a identificação precisa de suas interdependências por meio de métodos convencionais [7]. Além disso, aspectos demográficos, como idade avançada, gênero e etnia, influenciam diretamente a prevalência e a progressão da doença, sendo mais frequente em homens e em populações urbanas [8].

Para compreender melhor essas interações, a teoria dos grafos apresenta-se como uma ferramenta promissora. Essa abordagem permite modelar e visualizar as relações entre variáveis interdependentes de maneira estruturada. Por meio de matrizes de correlação, as conexões entre variáveis podem ser representadas em grafos ponderados, nos quais os nós simbolizam as variáveis e as arestas, suas interconexões, ponderadas pela força das correlações [4], [5]. Essa metodologia facilita a identificação de padrões latentes que poderiam ser ignorados em análises estatísticas tradicionais [7].

Neste estudo, busca-se explorar as correlações entre o DM2, suas comorbidades e fatores relacionados ao estilo de vida por meio da modelagem baseada em grafos. A partir de dados disponíveis em [1], elaborou-se uma matriz de correlação que foi utilizada para criar um grafo de conexões ponderadas, permitindo uma análise visual e quantitativa das inter-relações entre as variáveis. Essa abordagem visa não apenas identificar os fatores mais influentes na rede de correlações, mas também destacar como variáveis modificáveis podem ser aproveitadas em intervenções mais eficazes.

A estrutura deste artigo está organizada para contextualizar e detalhar a abordagem proposta. Primeiramente, apresenta-se uma revisão das limitações das metodologias tradicionais para análise de correlações complexas no contexto do DM2. Em seguida, descreve-se a modelagem baseada em grafos, incluindo o processo de construção e análise do grafo. Os resultados são discutidos, evidenciando padrões significativos e interdependências entre diabetes, comorbidades e fatores comportamentais.

II. CONTEXTUALIZAÇÃO

O diabetes mellitus tipo 2 (DM2) é uma doença crônica amplamente prevalente em escala global, caracterizada pela resistência à insulina e pela secreção insuficiente desse hormônio pelas células β pancreáticas. Apesar de ter sido reconhecido como uma questão médica relevante no início do século XX, os avanços mais significativos em sua compreensão ocorreram a partir da segunda metade do século, com o desenvolvimento de métodos laboratoriais para medir os níveis de glicose e insulina no sangue.

Na década de 1970, pesquisas pioneiras identificaram a obesidade e o sedentarismo como fatores de risco primários para o DM2. Nesse mesmo período, foi proposta a relação entre resistência à insulina e a síndrome metabólica, expandindo

a compreensão sobre a complexidade dessa condição. Já nos anos 1990, grandes estudos epidemiológicos populacionais proporcionaram avanços importantes, mapeando a prevalência global do DM2 e revelando disparidades regionais significativas.

Mais recentemente, o advento de tecnologias computacionais avançadas viabilizou o uso de big data e aprendizado de máquina para explorar as relações entre diferentes fatores de risco. Além disso, a teoria dos grafos, originalmente desenvolvida na matemática e na ciência da computação, começou a ser aplicada no campo biomédico, oferecendo novas possibilidades para analisar padrões complexos e interações entre variáveis. Essa abordagem se destaca por sua capacidade de modelar sistemas multifatoriais, mostrando-se especialmente promissora no estudo do DM2, ao permitir uma análise aprofundada e visual das inter-relações entre fatores demográficos, metabólicos e comportamentais.

Projeções da Organização Mundial da Saúde (OMS) indicam que, até 2045, aproximadamente 693 milhões de pessoas terão diabetes, representando um grande desafio para os sistemas de saúde pública [8]. Entre as principais complicações associadas ao DM2, destacam-se doenças cardiovasculares, nefropatia e neuropatia, que afetam gravemente a qualidade de vida dos pacientes. A relação entre os fatores de risco associados ao DM2 é altamente complexa, envolvendo variáveis metabólicas, comportamentais e demográficas, como obesidade, hipertensão arterial, envelhecimento, inatividade física e padrões alimentares inadequados. Essas variáveis apresentam interdependências que nem sempre são capturadas com eficácia por abordagens analíticas tradicionais.

Além disso, fatores psicossociais, como a saúde mental e o impacto do diagnóstico na mobilidade física, exercem uma influência significativa na progressão da doença. Nesse contexto, a teoria dos grafos surge como uma ferramenta inovadora para lidar com essa complexidade, permitindo que variáveis sejam representadas como nós em uma rede, enquanto suas inter-relações são visualizadas como arestas ponderadas. Essa abordagem facilita a identificação de padrões latentes e variáveis-chave em sistemas multifatoriais, como o DM2.

Neste estudo, a teoria dos grafos foi utilizada para investigar as conexões entre fatores de risco associados ao DM2, com foco em condições como hipertensão arterial, colesterol elevado e limitações na mobilidade. A modelagem gráfica proporciona uma perspectiva integrada e inovadora, indo além das análises estatísticas convencionais, que frequentemente não conseguem captar a totalidade das interdependências entre variáveis.

A contextualização apresentada nesta seção estabelece a base para compreender a motivação e a relevância da metodologia adotada, detalhada na próxima seção, bem como os resultados e discussões apresentados ao longo deste trabalho.

III. TRABALHOS CORRELATOS

O estudo dos fatores de risco associados ao diabetes mellitus tipo 2 (DM2) tem despertado crescente interesse devido

à complexidade das interações entre variáveis metabólicas, comportamentais e demográficas. Diversas pesquisas utilizam métodos estatísticos e computacionais para explorar essas relações, empregando desde análises tradicionais de regressão até técnicas mais avançadas, como aprendizado de máquina e modelagem em grafos.

Em [6], os autores investigaram a manutenção de níveis glicêmicos em pacientes com DM2, correlacionando esses indicadores com hábitos de vida, como alimentação e prática de exercícios físicos. Embora o estudo tenha identificado padrões relevantes, sua abordagem foi restrita à análise isolada de variáveis, sem considerar interdependências mais amplas entre os fatores examinados. De maneira complementar, o trabalho de Malta et al. [7] analisou fatores relacionados ao diabetes em adultos brasileiros utilizando dados da Pesquisa Nacional de Saúde (PNS). Nesse estudo, os autores observaram associações estatísticas entre DM2, hipertensão, obesidade e inatividade física; contudo, a ausência de uma modelagem visual das conexões dificultou a identificação de padrões mais complexos.

Outros estudos também abordaram aspectos específicos do DM2. Por exemplo, Chen et al. [3] investigaram a relação entre níveis de carotenoides e o risco de síndrome metabólica, trazendo insights bioquímicos valiosos. Entretanto, essas pesquisas focaram em subgrupos limitados de variáveis, sem considerar a inter-relação sistêmica que caracteriza o DM2. De forma semelhante, Araujo et al. [4] aplicaram matrizes de correlação de Pearson em estudos operacionais, mas não avançaram na transformação dessas matrizes em representações gráficas, que poderiam oferecer uma visão mais intuitiva e detalhada das interdependências entre as variáveis.

Este trabalho se propõe a contribuir para o campo ao adotar a teoria dos grafos como uma abordagem inovadora para modelar e visualizar as complexas interações entre fatores de risco relacionados ao DM2. Diferentemente de estudos anteriores, a metodologia apresentada aqui permite não apenas identificar variáveis críticas, mas também explorar como essas variáveis interagem em uma rede mais ampla. Assim, padrões latentes que poderiam ser ignorados por abordagens convencionais tornam-se mais evidentes. Além disso, a visualização por meio de grafos facilita a comunicação de resultados complexos e pode servir como suporte para o desenvolvimento de políticas públicas e intervenções direcionadas.

Essa abordagem complementa estudos como o de Lopes et al. [5], que introduziram técnicas exploratórias de dados com o uso da linguagem Python, e o de Varges et al. [6], que enfatizaram a importância do controle glicêmico no manejo do DM2. Ao integrar métodos computacionais avançados com representações gráficas intuitivas, este estudo se diferencia ao oferecer uma análise abrangente das interações entre variáveis relacionadas ao diabetes tipo 2. Tais contribuições reforçam a relevância de ferramentas analíticas robustas para enfrentar os desafios multifatoriais associados a essa condição.

IV. METODOLOGIA

Neste estudo, a metodologia foi organizada em três etapas principais: ferramentas utilizadas, preparação dos dados e modelagem dos grafos. Cada uma dessas etapas é detalhada a seguir.

A. Ferramentas Utilizadas

Para o desenvolvimento deste estudo, utilizou-se a linguagem de programação Python, amplamente reconhecida por sua extensa gama de bibliotecas dedicadas à análise de dados e visualização gráfica. Entre as bibliotecas empregadas, destacam-se: *pandas*, utilizada para manipulação e análise eficiente de dados tabulares; *numpy*, responsável por cálculos matemáticos; e *matplotlib* e *networkx*, essenciais para a criação e visualização de grafos.

O ambiente computacional foi composto por um computador equipado com processador AMD Ryzen 5 5500U com Radeon Graphics (2,10 GHz), 8 GB de RAM e sistema operacional Ubuntu 24.04. A implementação do código foi realizada no editor de texto *Visual Studio Code*, que, devido à sua integração com ferramentas de análise e depuração, garantiu um fluxo de trabalho eficiente e organizado.

B. Preparação dos Dados

Os dados utilizados neste estudo foram obtidos no repositório Kaggle e armazenados no Zenodo para referência futura [1]. A base de dados, no formato CSV, continha informações relacionadas a variáveis clínicas, comportamentais e de estilo de vida associadas ao diabetes tipo 2.

A preparação dos dados seguiu três etapas principais. Primeiramente, a base foi lida utilizando a biblioteca *pandas*, que converteu os dados em um *DataFrame*, estrutura ideal para manipulação e análise de dados tabulares. Posteriormente, valores ausentes foram identificados e removidos, de modo a evitar inconsistências nos cálculos de correlação. Em uma segunda etapa, as variáveis categóricas foram transformadas em numéricas utilizando o método de *Label Encoding*, garantindo compatibilidade com as operações matemáticas subsequentes. Finalmente, as variáveis contínuas foram normalizadas para o intervalo $[0, 1]$ utilizando a técnica de *Min-Max Scaling*, assegurando que discrepâncias na escala das variáveis não influenciassem os resultados da análise.

Essas etapas foram cruciais para garantir a integridade e a comparabilidade dos dados, oferecendo uma base sólida para a construção e análise dos grafos.

C. Modelagem dos Grafos

A modelagem dos grafos foi dividida em duas etapas principais: construção do grafo geral a partir da matriz de correlação e criação do grafo filtrado, que destacou apenas as conexões mais significativas.

1) Correlação de Matriz

A construção do grafo geral baseou-se em uma matriz de correlação calculada utilizando a biblioteca *pandas*. Para quantificar a força e a direção da relação linear entre variáveis,

utilizou-se o coeficiente de correlação de Pearson. A fórmula matemática utilizada para esse cálculo é apresentada abaixo:

$$r_{X,Y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \cdot \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}}, \quad (1)$$

onde X_i e Y_i representam os valores individuais das variáveis X e Y , \bar{X} e \bar{Y} indicam suas médias, e n é o número total de observações.

A matriz de correlação obtida foi convertida em um grafo não direcionado e ponderado. Nesse grafo, os nós representaram as variáveis presentes na base de dados, enquanto as arestas conectaram variáveis com base nos valores de correlação. O peso das arestas foi definido pela magnitude dos coeficientes de correlação.

O grafo foi visualizado utilizando a biblioteca *networkx*, com a aplicação do algoritmo de disposição *Spring Layout*, que distribui os nós de forma a maximizar a clareza estrutural e a estética da representação gráfica.

O algoritmo utilizado para construir o grafo geral pode ser descrito no pseudocódigo apresentado a seguir:

Algorithm 1: Construção do Grafo Geral a partir da Matriz de Correlação

Require: Conjunto de dados (*data*)

Ensure: Grafo geral (*Graph*) com arestas ponderadas por correlação

- 1: Calcular a matriz de correlação
 $corrMatrix = data.corr()$
 - 2: Inicializar o grafo vazio *Graph*
 - 3: **foreach** variável X em $data.columns$ **do**
 - 4: Adicionar nó X ao *Graph*
 - 5: **foreach** pares de variáveis (X, Y) em $corrMatrix$ **do**
 - 6: **if** $X \neq Y$ e $corrMatrix[X, Y]$ não é NaN **then**
 - 7: Adicionar aresta entre X e Y com peso $|r_{X,Y}|$
 - 8: Definir a posição dos nós usando *spring layout*
 - 9: Desenhar o grafo com arestas ponderadas e nós rotulados
 - 10: Exibir o grafo
 - 11: **return** *Graph*
-

2) Grafo Filtrado

Com o objetivo de destacar as conexões mais significativas e simplificar a interpretação dos resultados, foi aplicado um limiar de correlação ao grafo geral. Apenas as arestas com valores de correlação superiores a um limiar predefinido (por exemplo, $|r_{X,Y}| > 0.5$) foram mantidas no grafo filtrado. Variáveis que não apresentavam conexões acima desse limiar foram removidas, resultando em um grafo mais compacto e direcionado.

O pseudocódigo correspondente ao processo de filtragem é apresentado abaixo:

Algorithm 2: Construção do Grafo Filtrado

Require: Grafo geral (*Graph*), limiar de correlação (*threshold*)

Ensure: Grafo filtrado (*FilteredGraph*)

```
1: foreach arestas (X, Y) em Graph do
2:   if peso da aresta (X, Y) < threshold then
3:     Remove aresta (X, Y) de Graph
4: Identificar nós isolados em Graph
5: Remover todos os nós isolados
6: Definir a posição dos nós usando spring layout
7: Desenhar o grafo filtrado com arestas ponderadas e
   nós rotulados
8: Exibir o grafo
9: return FilteredGraph
```

O grafo filtrado permitiu destacar variáveis críticas, como hipertensão, colesterol elevado, índice de massa corporal (BMI) e histórico de doenças cardiovasculares, possibilitando uma análise mais focada das conexões relevantes. A simplificação do grafo garantiu uma visualização mais clara e objetiva das principais inter-relações entre fatores de risco.

As etapas descritas nesta seção proporcionaram uma modelagem eficiente dos dados, permitindo a identificação de padrões significativos e a exploração das interconexões entre variáveis associadas ao diabetes tipo 2. A utilização da teoria dos grafos demonstrou ser uma abordagem inovadora e poderosa para representar a complexidade presente nos dados.

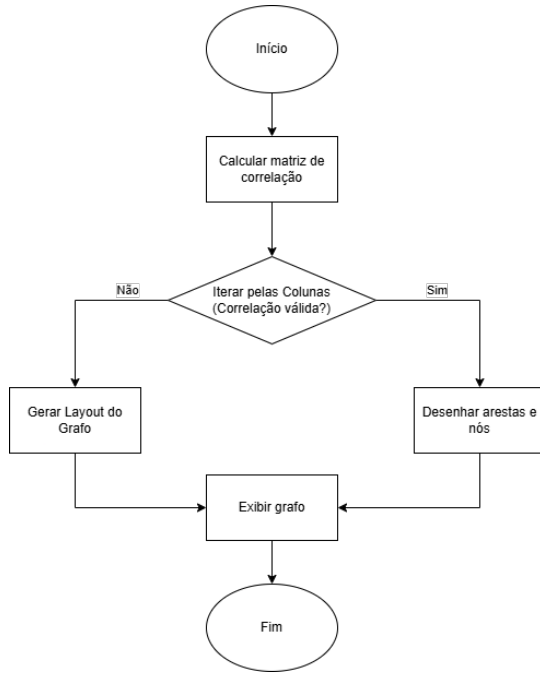


Fig. 1. Fluxograma do processo de modelagem dos grafos, detalhando as etapas desde o cálculo da matriz de correlação até a exibição do grafo final.

V. RESULTADOS E DISCUSSÃO

A. Resultados

A análise dos dados revelou padrões marcantes na distribuição do diabetes tipo 2 e suas associações com fatores de risco. A Figura 2 apresenta a distribuição de casos por faixa etária, evidenciando um aumento progressivo no número de casos a partir dos 40 anos, com pico entre 65 e 69 anos. Esse comportamento está alinhado com estudos epidemiológicos anteriores que indicam uma correlação positiva entre o avanço da idade e a prevalência de condições metabólicas crônicas, como o diabetes tipo 2.

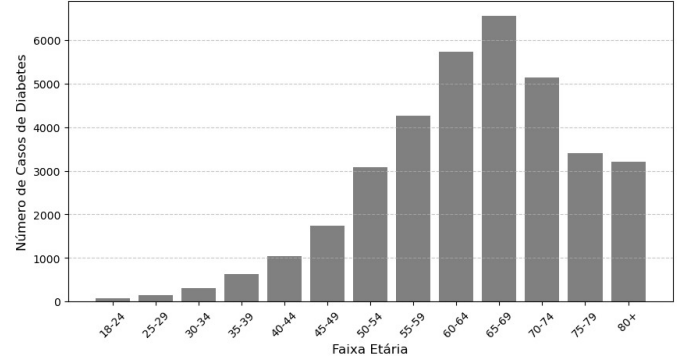


Fig. 2. Distribuição de casos de diabetes por faixa etária.

Adicionalmente, a análise por gênero revelou um comportamento interessante, como mostrado na Figura 3. Embora o número absoluto de pacientes do sexo feminino seja maior, nota-se que a proporção de casos confirmados de diabetes (código 1.0) entre os gêneros é relativamente equilibrada. Esse dado sugere que, independentemente do gênero, fatores como envelhecimento e condições metabólicas desempenham um papel central na prevalência do diabetes tipo 2.

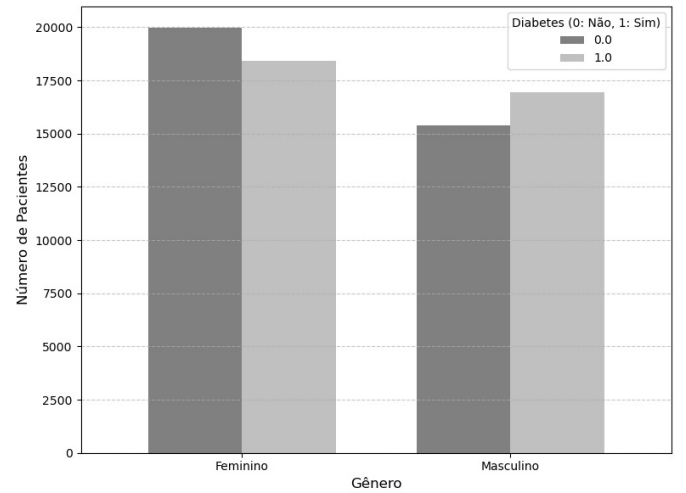


Fig. 3. Distribuição de pacientes com e sem diabetes por gênero.

A Figura 4 apresenta o grafo geral de correlações, no qual cada nó representa uma variável do conjunto de dados,

enquanto as arestas indicam a força da correlação entre elas. Esse grafo ilustra a complexa rede de inter-relações entre diabetes, comorbidades e fatores comportamentais, oferecendo uma visão ampla e integrada das conexões que influenciam a saúde metabólica.




Fig. 4. Grafo geral de correlações.

Para simplificar a interpretação, foi gerado um grafo filtrado (Figura 5), que mantém apenas as conexões mais significativas. Este grafo destaca variáveis-chave, como hipertensão (HighBP), colesterol elevado (HighChol), índice de massa corporal (BMI) e histórico de doenças cardiovasculares (HeartDiseaseorAttack), reforçando a importância dessas variáveis no contexto do diabetes.




Fig. 5. Grafo de correlações com conexões mais significativas.

B. Discussão

Os resultados apresentados oferecem um panorama abrangente das inter-relações entre fatores de risco associados ao diabetes tipo 2, evidenciando como variáveis demográficas, comportamentais e metabólicas estão interconectadas. A análise por faixa etária (Figura 2) demonstrou que o avanço da idade está intimamente associado ao aumento da prevalência do diabetes tipo 2, especialmente em indivíduos acima de 40 anos. Esse padrão corrobora estudos epidemiológicos que atribuem esse fenômeno a fatores como maior resistência à insulina, redução da função das células β pancreáticas e aumento do acúmulo de gordura visceral, todos contribuintes para o desenvolvimento da doença [2].

A análise por gênero (Figura 3) revelou que, embora o número absoluto de mulheres diagnosticadas com diabetes seja maior, a prevalência proporcional entre homens e mulheres é equilibrada. Isso sugere que fatores metabólicos, como resistência à insulina e obesidade, têm um papel mais preponderante no desenvolvimento da doença do que diferenças relacionadas ao gênero. No entanto, estudos prévios indicam que mulheres podem enfrentar desafios adicionais no manejo do diabetes, como maiores taxas de comorbidades e diferenças na resposta aos tratamentos, o que demanda investigações mais detalhadas.

Os grafos gerados (Figuras 4 e 5) destacaram as variáveis mais influentes e suas inter-relações no contexto do diabetes tipo 2. O grafo geral revelou uma ampla rede de conexões entre variáveis clínicas, comportamentais e demográficas, destacando, por exemplo, a forte correlação entre hipertensão (HighBP) e colesterol elevado (HighChol) com o diabetes. Esses resultados corroboram estudos que associam essas condições metabólicas a mecanismos subjacentes, como inflamação crônica e resistência à insulina, os quais são determinantes no desenvolvimento do diabetes tipo 2.

Por outro lado, o grafo filtrado simplificou a análise, destacando conexões mais significativas, como a associação entre obesidade (BMI) e diabetes. Outra conexão importante evidenciada foi entre atividade física reduzida (PhysActivity) e dificuldade de locomoção (DiffWalk). Essas descobertas reforçam a importância de intervenções baseadas em estilo de vida, incluindo programas de exercícios físicos regulares e mudanças nos padrões alimentares, que podem reduzir o risco de diabetes de maneira substancial.

Outro ponto de destaque foi a conexão entre saúde mental (MentHlth) e diabetes tipo 2. Estudos recentes indicam que transtornos como ansiedade e depressão estão associados a um aumento do risco de diabetes, seja por alterações hormonais que afetam o metabolismo da glicose, seja pela dificuldade em manter hábitos saudáveis. Esses dados enfatizam a necessidade de integrar suporte psicológico nas estratégias de manejo do diabetes, desenvolvendo abordagens multidisciplinares para abordar tanto os aspectos emocionais quanto os físicos da doença [6].

1) Implicações Clínicas

As descobertas deste estudo possuem implicações clínicas significativas. A identificação de variáveis-chave, como hipertensão, obesidade e saúde mental, fornece uma base sólida para intervenções personalizadas voltadas à prevenção e ao manejo do diabetes tipo 2. Estratégias baseadas em mudanças no estilo de vida, como aumento da atividade física e educação nutricional, são particularmente eficazes na redução da resistência à insulina e na mitigação de complicações metabólicas.

No ambiente clínico, os profissionais de saúde podem aplicar os dados deste estudo para melhorar a triagem de pacientes, priorizando o monitoramento de indivíduos com múltiplos fatores de risco interconectados. Por exemplo, pacientes com alta dificuldade de locomoção (*DiffWalk*) e altos índices de massa corporal (BMI) apresentam maior risco de complicações metabólicas e devem ser alvo de monitoramento mais frequente. Além disso, a visualização de conexões por meio de grafos pode ser implementada em sistemas de suporte à decisão clínica, auxiliando médicos e nutricionistas na escolha de intervenções mais direcionadas e eficazes.

2) Desafios e Limitações

Apesar das contribuições deste estudo, algumas limitações precisam ser destacadas. A qualidade e a abrangência dos dados utilizados, coletados de um repositório público, podem ter sido influenciadas por vieses de amostragem e representatividade. Além disso, a ausência de dados longitudinais limita a capacidade de inferir causalidade entre as variáveis identificadas.

Outro desafio está relacionado ao uso de limiares de correlação para simplificar o grafo filtrado. Embora esse processo torne a interpretação mais prática, ele pode excluir conexões relevantes cuja correlação esteja abaixo do limiar predefinido. Abordagens alternativas, como modelos de análise multivariada, poderiam complementar as descobertas realizadas.

Adicionalmente, é importante destacar que a presença de conexões em um grafo não implica necessariamente causalidade. Portanto, os resultados devem ser validados por estudos clínicos e experimentais. Por fim, a generalização dos dados para outras populações deve ser feita com cautela, considerando diferenças em contextos socioeconômicos e regionais, que podem influenciar a dinâmica das inter-relações entre variáveis.

Este estudo reforça a relevância de intervenções integradas que combinem manejo metabólico, suporte psicológico e promoção de mudanças no estilo de vida. A aplicação da teoria dos grafos demonstrou ser uma ferramenta poderosa para capturar a complexidade das inter-relações entre fatores de risco, oferecendo insights que podem orientar tanto práticas clínicas quanto políticas públicas. Contudo, estudos futuros devem abordar as limitações apresentadas, ampliando a aplicabilidade e a robustez das análises realizadas.

VI. CONCLUSÃO

Este estudo evidenciou o potencial da teoria dos grafos como uma ferramenta analítica poderosa na identificação de fatores de risco associados ao diabetes tipo 2, oferecendo uma abordagem inovadora e visual para explorar padrões complexos de interdependências entre variáveis. A partir da matriz de correlação gerada, foi possível modelar uma rede que revelou conexões significativas entre diabetes, comorbidades metabólicas e cardiovasculares, além de fatores comportamentais.

Os resultados obtidos destacaram hipertensão, colesterol elevado, obesidade e histórico de doenças cardiovasculares como variáveis centrais dentro da rede de correlações, corroborando dados amplamente descritos na literatura científica. Além disso, a inclusão de variáveis como saúde mental e dificuldade de locomoção proporcionou uma perspectiva mais ampla e multidimensional, ressaltando o impacto psicológico e funcional que o diabetes tipo 2 exerce na qualidade de vida dos pacientes. Esses dados reforçam a necessidade de intervenções preventivas e multidisciplinares que combinem controle metabólico, suporte psicológico e a promoção de atividades físicas regulares.

A metodologia apresentada demonstrou vantagens claras em relação às abordagens estatísticas tradicionais, ao oferecer uma representação estruturada e intuitiva das relações entre variáveis. A visualização gráfica das conexões permite uma compreensão mais clara das inter-relações complexas, facilitando a comunicação dos resultados e a formulação de estratégias baseadas em evidências. Essa abordagem possui potencial para ser ampliada e aplicada em outros contextos de saúde pública, contribuindo para o desenvolvimento de políticas mais eficazes e integradas para o manejo de condições crônicas, como o diabetes tipo 2 e suas comorbidades.

Como perspectivas futuras, recomenda-se a integração de técnicas preditivas baseadas em aprendizado de máquina com a análise de redes, visando prever a progressão do diabetes em diferentes populações e contextos. Essa integração permitiria identificar padrões emergentes e antecipar tendências, ampliando a eficácia de intervenções preventivas. Além disso, a inclusão de dados longitudinais poderia aprofundar a compreensão das dinâmicas temporais entre os fatores de risco, possibilitando uma análise mais detalhada da evolução da doença ao longo do tempo.

Com a aplicação desta abordagem, espera-se contribuir para uma gestão mais eficiente e personalizada do diabetes tipo 2, promovendo melhorias na saúde e qualidade de vida dos pacientes. Adicionalmente, os dados deste estudo podem apoiar a formulação de estratégias de saúde pública mais integradas, voltadas tanto à prevenção quanto ao manejo da doença, garantindo um impacto positivo em diferentes populações e contextos socioeconômicos.

REFERÊNCIAS

- [1] Eduardo da Silva Torres Grillo, "Diabetes_data". Zenodo, fev. 05, 2025. doi: <https://zenodo.org/records/14806872>.

- [2] McLellan, K. C. P., Barbalho, S. M., Cattalini, M., Lerário, A. C. "Diabetes mellitus do tipo 2, síndrome metabólica e modificação no estilo de vida." *Revista De Nutrição*, vol. 20, n. 5, 2007, pp. 515-524. Disponível em: <https://doi.org/10.1590/s1415-52732007000500007>.
- [3] Chen, M., Cai, S., Jia, Q., Suo, Y., Tang, Y., Shi, Y., Zhu, X., Zhang, H. "Inverse Relationship Between Serum Carotenoid Levels and Cardiovascular-Kidney-Metabolic Syndrome Among the General Adult Population." **Journal of Diabetes**, vol. 17, 2025, e70046. Disponível em: <https://doi.org/10.1111/1753-0407.70046>.
- [4] Araujo, J. V. G. A., dos Santos, M., Gomes, C. F. S. (2019). "Desenvolvimento de um código em Python para geração de Matrizes de Correlação de Pearson com laços a partir de 'n' variáveis tomadas duas a duas." *Simpósio de Pesquisa Operacional e Logística da Marinha*, Rio de Janeiro, RJ, Brasil.
- [5] Lopes, Gesiel, Almeida, Alessandro, Delbem, Alexandre, Toledo, Claudio. (2019). "Introdução à Análise Exploratória de Dados com Python."
- [6] Varges, Jefferson, Santos, Tayanne, Barros, Mariana. (2021). "Avaliação da manutenção de níveis glicêmicos em pacientes portadores de diabetes tipo 2, correlacionando com seus hábitos de vida." **Research, Society and Development**, vol. 10, e38710716857. Disponível em: <https://doi.org/10.33448/rsd-v10i7.16857>.
- [7] D. Malta, R. Bernal, A. Sá, T. Silva, B. Iser, B. Duncan et al., "Diabetes autorreferido e fatores associados na população adulta brasileira: pesquisa nacional de saúde, 2019." **Ciência Saúde Coletiva**, vol. 27, no. 7, pp. 2643-2653, 2022. Disponível em: <https://doi.org/10.1590/1413-81232022277.02572022>.
- [8] V. C. dos Santos, "Diabetes Mellitus Tipo 2 - aspectos epidemiológicos, fisiopatológicos e manejo terapêutico." **Braz. J. Develop.**, vol. 9, no. 3, pp. 9737-9749, Mar. 2023.